FUNDAMENTOS DE APRENDIZAGEM DE MÁQUINA

Maikon Lucian Lenz



SAGAH SOLUÇÕES EDUCACIONAIS INTEGRADAS

Introdução à aprendizagem de máquina

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Definir a área de aprendizagem e a sua terminologia.
- Demonstrar o processo de aprendizado de máquina.
- Identificar as tarefas do aprendizado de máquina.

Introdução

A inteligência artificial compreende diversas habilidades desejadas aos sistemas, e o aprendizado de máquina é uma das mais utilizadas nos dias de hoje por sua capacidade de resolução de problemas complexos ou de grande volume de dados. O processo de aprendizado consiste no treinamento de um algoritmo ou modelo para que possa criar regras que relacionam os dados de entrada (atributos previsores) com os dados de saída (atributo alvo), permitindo a realização de tarefas como classificação, previsão e agrupamento de dados. Dessa forma, o essencial no aprendizado de máquina é o reconhecimento de padrões, ou seja, a busca por semelhanças entre as características de diferentes instâncias de determinado conjunto de dados.

Quando a máquina é capaz de aprender de forma autônoma, inúmeras soluções podem ser desenvolvidas. O aprendizado facilita a descrição de dados cujas características e informações são de pouco conhecimento. Também permite que a quantidade de informações produzidas por uma empresa ou laboratório sejam mais bem aproveitadas, buscando correlações entre informações que, de outra forma, seriam ignoradas. Além disso, o aprendizado de máquina é capaz de antecipar situações a partir da experiência acumulada para diversos sistemas e até mesmo sugerir itens relevantes para o usuário de determinado produto com base no conhecimento que a máquina acumulou do seu comportamento,

o que seria demasiadamente complexo de se implementar, uma vez que demandaria a produção customizada de aplicativos.

Neste capítulo, você conhecerá o aprendizado de máquina e as terminologias associadas. Serão apresentadas tarefas de aprendizado, como classificação, regressão e agrupamento, além de exemplos de situações em que cada uma é aplicada.

1 Aprendizado de máquina

As taxas de processamento, capacidade de armazenamento e possibilidades de interação das máquinas com o meio físico ultrapassam o tempo e o volume de informações manipuláveis pelos indivíduos. Assim, é natural que, para manter o progresso tecnológico, alguma mudança radical de paradigma se faça necessária. As necessidades atuais, sejam individuais ou de um conjunto social, já não podem ser atendidas por sistemas digitais convencionais, programados a partir de regras lógicas simples, seguindo a sintaxe de uma linguagem de programação qualquer a partir de um modelo concebido por um único programador ou por uma equipe.

O volume de dados é um dos grandes empecilhos para que se possa analisar os dados em tempo hábil e encontrar uma solução válida. Apesar da popularidade dos sistemas especialistas a partir da década de 1970, em que eram mescladas as habilidades de programadores e indivíduos de notório saber na área do problema que se pretendia solucionar, já não era possível acompanhar a resolução dos problemas modernos (FACELI *et al*., 2011).

Estima-se que o volume de dados digitais dobra a cada vinte meses — levantamento feito ainda no ano 2005 (WITTEN; FRANK, 2005). Além disso, a possibilidade de aprender de forma contínua permitiu o desenvolvimento de novas aplicações que auxiliam desde projetos de pesquisa médica na busca por padrões em diagnósticos diversos até o controle de veículos autônomos, muito mais complexos que os sistemas que orientam a navegação do usuário.



Saiba mais

O aprendizado não é uma característica natural às máquinas, mas pode ser aproximado ou simulado, assim como outros tipos de comportamento, aproveitando técnicas adaptadas de outras áreas para os computadores, beneficiando-se das vantagens naturais das máquinas frente ao homem, como alta capacidade de processamento, repetibilidade e exatidão. Logo, o algoritmo em questão pode tomar decisões tão complexas quanto as tomadas por um indivíduo dotado de inteligência natural, como a interpretação de expressões faciais ou de voz humana, por exemplo.

A máquina precisa ser programada, ou seja, orientada sobre a forma que deve proceder com as informações que recebe. Para tanto, dispõe de um conjunto rígido de instruções para que, quando organizados de forma lógica, possam efetuar o trabalho esperado. Já o homem toma decisões e analisa o mundo ao seu redor a partir de regras nem sempre tão fáceis de identificar (FACELI *et al*., 2011). Assim, apesar de a máquina poder processar quantidades elevadas de informação, ela depende diretamente da qualidade do algoritmo desenvolvido e das ferramentas ou sensores associados a ela. Em outras palavras, a diferença entre uma máquina eficiente e outra ineficiente passa pela habilidade do desenvolvedor.

A inteligência artificial visa à implementação de rotinas em máquinas que possam aproximá-las do comportamento utilizado por agentes inteligentes na tomada de decisões. Assim, o aprendizado de máquina é um ramo da inteligência artificial cujo objetivo é habilitar um programa para melhorar seu desempenho na realização de determinada tarefa a partir da experiência obtida nas execuções anteriores (MITCHELL, 1997).

São muitos os processos e as tarefas que podem ser utilizados durante o aprendizado, geralmente, escolhidos de acordo com o tipo de problema ou dados disponíveis. Assim, um programa pode ser construído para identificar objetos em uma imagem a partir de exemplos previamente classificados entre os quais buscará padrões que permitam identificar os mesmos objetos em imagens futuras. Por exemplo, o computador de um táxi autônomo buscará melhorar seu desempenho durante o trajeto com base nas avaliações fornecidas pelo usuário ao final da corrida.

Em ambos os casos, o problema está conceituado de forma abstrata e resumida. Podem ser compreensíveis ao homem informações tão genéricas quanto objeto errado ou viagem horrível. Entretanto, mesmo para nós, conceitos mais objetivos precisam ser fornecidos para que os ajustes necessários sejam feitos; do contrário, será demasiadamente complexo reconhecer os erros cometidos e a forma como podem ser evitados. Assim, é importante que os elementos que compõem um problema de aprendizado sejam definidos.

Os dados referem-se às informações disponíveis para o sistema, tanto as recebidas quanto as emitidas pela máquina, de modo geral, referenciados como dados de entrada e saída, respectivamente. O grupo que engloba os dados de determinado sistema é denominado conjunto de dados. O conjunto de dados pode fazer menção a diferentes características de um sistema. Nem todos os dados de entrada referem-se à mesma característica, e isso também é válido para os dados de saída. Dessa forma, os dados também são organizados conforme a característica a que se referem. Essas características são conhecidas como atributos.

Por exemplo, os atributos de entrada do primeiro sistema (reconhecimento de objetos em imagens) podem conter cor do pixel, posição do pixel, transparência, entre outros. Já o atributo de saída poderia ser determinada categoria de objeto, como quadrado, círculo, carro, pessoa e assim por diante. Da mesma forma, o segundo exemplo teria atributos de entrada e saída específicos para o dado problema. Um único exemplar do conjunto de dados com todos os seus atributos é denominado instância. Imagine um conjunto de dados de carros cujos atributos são velocidade, cor e modelo. Uma instância diz respeito a um carro específico do conjunto de dados com as informações referentes a cada um dos seus atributos. Se os dados forem relacionados em uma tabela, os atributos, geralmente, seriam separados em colunas, e cada linha representaria uma instância.

Em aprendizado de máquina, as características de entrada e saída são definidas, respectivamente, como atributos previsores e atributos alvo ou meta, segundo a função que exercem no sistema (FACELI *et al*., 2011). Os atributos, sejam previsores ou alvos, podem ser qualitativos ou quantitativos. A forma como a máquina os armazena não se altera, todos os dados são, em último caso, números binários devido à natureza dos circuitos que a compõem, contudo, o significado atribuído a eles pode diferir de acordo com o contexto em que se encontram.

Atributos qualitativos dizem respeito a propriedades, e não a quantidades da instância. São divididos em: nominais, quando um valor específico representa determinada característica, por exemplo, a cor de um objeto expressa de forma textual; ordinais, quando o valor representa a ordem ou posição de determinado objeto e tem importância para o seu significado, como a posição de chegada em uma corrida; ou binários, quando representam apenas um estado ou seu inverso. Atributos quantitativos, por sua vez, fazem menção ao número de itens presentes e são divididos em: discretos, quando existe uma quantidade finita de valores possíveis, como o número de indivíduos pertencentes a determinado grupo; e contínuos, quando qualquer valor pode ser atribuído a uma característica, como o peso ou preço de um objeto.

No entanto, não são todos os atributos conhecidos de uma instância ou sistema que têm relevância para se determinar o atributo alvo. Dessa forma, os atributos previsores serão restritos aos que permitem diferenciar as instâncias. Não faz sentido, por exemplo, utilizar as informações de idade e data de nascimento de uma pessoa ao mesmo tempo durante a avaliação de exames médicos cujo fator idade tenha influência sobre o resultado, uma vez que a data de nascimento não agregará informação relevante à idade já conhecida do indivíduo e, portanto, não influenciará o resultado do diagnóstico. Da mesma forma, pouco importa a cor de um objeto para se determinar a sua forma.

Assim, é importante reconhecer que os atributos de qualquer tipo precisam ser adequados à forma de representação utilizada pela máquina, mas também avaliados quanto à relevância de sua contribuição para o algoritmo. A cor de um objeto pode ser traduzida para um número segundo uma tabela de cores; já a quantidade de um atributo pode ser representada de forma direta. Em qualquer caso, o que muda é apenas o significado e a forma como os dados são utilizados, cabe ao desenvolvedor encontrar meios adequados de representar a informação para os diferentes tipos de atributos.

Os meios de programação de uma máquina também são restritos segundo as suas características físicas. As máquinas compreendem conjuntos restritos e bem definidos de instruções, que podem ser expressas conforme a sintaxe estabelecida por ela em um nível de programação mais próximo do *hardware* ou do programador, quando se recorre a linguagens de alto nível. A grande diferença das instruções fornecidas à máquina em um algoritmo convencional quando comparadas a sistemas dotados de aprendizado de máquina está na forma como o problema é abordado. Enquanto, no primeiro caso, são especificadas as regras que transformam informações de entrada em informações de saída, o aprendizado de máquina visa ao descobrimento dessas regras de

forma autônoma pela máquina, e os meios de avaliar o desempenho obtido até o momento são fornecidos, assim como o modo de buscar novas hipóteses que possam ser testadas futuramente.

Em outras palavras, o aprendizado de máquina visa à descoberta de regras ou parâmetros que relacionam as entradas e as saídas, e o sistema pode ser alimentado com exemplos de entrada e saída válidos ou produzir novos dados de entrada de maneira aleatória para avaliar a eficiência do que foi aprendido até o momento. Enquanto isso, as regras ou parâmetros que relacionam entradas e saídas são definidos explicitamente pelo programador nos algoritmos tradicionais. Em resumo, compreende-se por aprendizado de máquina o algoritmo capaz de melhorar de forma repetida o seu desempenho a partir da experiência absorvida após avaliar diferentes conjuntos de dados, inferindo regras ou parâmetros que permitam identificar o atributo alvo a partir dos atributos de entrada utilizados.

2 Processo de aprendizado de máquina

O aprendizado de máquina pressupõe o acúmulo de conhecimento e, portanto, de extração de significado a partir de determinado conjunto de dados. Esse processo pode ser dividido em sete etapas: coleta de dados, preparação dos dados, seleção do modelo, treinamento, avaliação, ajuste de parâmetros e aplicação (Figura 1).



Figura 1. Processo geral do aprendizado de máquina.

Primeiramente, os dados devem ser selecionados em quantidade e qualidade suficientes para extrair o conhecimento necessário. Quanto maior a quantidade de exemplos/amostras obtidos, melhor será o aprendizado. Em contrapartida, a qualidade tem relação direta com os atributos escolhidos. Devem ser priorizados os de maior relevância para o modelo. Os dados obtidos podem incluir, dependendo do tipo de aprendizado, tanto atributos previsores quanto atributos alvo.

Na sequência, os dados devem ser preparados e adequados ao modelo utilizado. Nessa etapa, estão incluídas as transformações de unidade, conversão de escala, normalização, discretização e mudanças de representação dos dados. É importante avaliar o balanceamento dos dados, ou seja, se os dados coletados para diferentes faixas ou classes de previsão estão presentes em quantidades equivalentes. Dados incompletos, inconsistentes, duplicados ou ruidosos devem ser tratados ou eliminados para que não influenciem o processo de treinamento, distorcendo o aprendizado (FACELI *et al.*, 2011). Os dados podem ainda ser separados em dois grupos, um para ser utilizado na etapa de treinamento e outro para testes. Essa medida evita que se confunda um modelo especializado no conjunto de dados de treinamento com um modelo capaz de generalizar o aprendizado e fazer previsões corretas para dados até então desconhecidos.

Na etapa de seleção do modelo, devem ser observadas as vantagens oferecidas para o tipo de dados envolvidos e para a complexidade de cada um deles. Os modelos podem incluir regressões lineares, regressões logísticas, classificação, agrupamento, aprendizado profundo, entre outros. A quarta etapa é o cerne do aprendizado de máquina: o treinamento. Nela, a intenção é aprimorar o modelo a cada nova amostra de treinamento avaliada. Um problema simples e linear, representado por apenas uma característica, pode ser determinado segundo a equação a seguir:

$$y = b + w \, . \, x$$

onde:

- y = saída
- x = entrada
- b = viés
- w = peso

O treinamento altera o modelo especificado pela equação modificando os parâmetros de viés (b) e o peso (w), já que os demais não podem ser alterados. A quantidade de parâmetros pode ser maior conforme a quantidade de atributos previsores aumenta. É essencial que o algoritmo tenha meios de avaliar ou comparar os resultados obtidos para o modelo em cada passo do teste realizado. O treinamento consiste na inferência de hipóteses que mais se aproximem do resultado adequado para a saída a partir de determinado conjunto de dados de

entrada (FACELI *et al*., 2011). A máquina deve ser programada para buscar a constante redução do conjunto de hipóteses durante o treinamento.

Em seguida, a etapa de avaliação utiliza os dados separados inicialmente para efetuar os testes e determinar se o modelo obtido após o treinamento tem a precisão esperada na predição do alvo a partir de conjuntos de dados até então desconhecidos. Concluída a etapa de avaliação, podem ser definidos novos hiperparâmetros (que controlam o processo de aprendizado em si) que incluem: quantidade de repetições de todo o processo sobre o conjunto de dados de treinamento; taxa de aprendizado, fator para as mudanças de parâmetros do modelo; entre outros. Por fim, a etapa de aplicação diz respeito ao uso do modelo para a realização de previsões a partir da máquina já treinada.

De forma sucinta, o processo de aprendizado consiste na coleta de dados adequados para o modelo escolhido que deverá ser treinado, avaliado e refinado para que predições corretas possam ser feitas para dados futuros. Para que o conjunto inicial de hipóteses leve a máquina até o ponto em que seja encontrada a solução ideal que relacione as entradas às saídas, espera-se que a solução já esteja presente nele. Sem qualquer juízo ou avaliação prévia, é evidente que uma solução perfeita só será possível caso o conjunto de hipóteses contenha sempre todas as possibilidades de resolução do problema. Isso acarreta grande volume de informação e processamento e contribui negativamente para a agilidade do processo (COPPIN, 2010).

De qualquer forma, o que se busca com repetitivas reduções do conjunto de hipóteses é obter um subconjunto que caracterize as hipóteses de solução mesmo que nem sempre seja possível atingir um resultado que se encaixe perfeitamente no padrão. Caso o modelo adotado seja bem-sucedido e sejam dadas iterações suficientes para que a máquina possa aprender, o resultado deverá ser uma hipótese de solução válida não só para os dados utilizados no processo de treinamento, mas também para casos futuros. Quanto mais os resultados esperados e obtidos convergirem, maior será a capacidade de generalização da hipótese. Do contrário, caso não fosse possível generalizar, o resultado não seria um algoritmo considerado inteligente, mas um especialista nos dados treinados. Nesse caso, é provável que a máquina tenha apenas memorizado os dados anteriores (FACELI *et al*., 2011). Isso pode ser analogamente comparado a um ser humano que apenas decorou as soluções de um problema sem nada compreender sobre a sua estrutura, regras, conceitos e assim por diante.

A capacidade de generalização pode variar com a estrutura e o modelo de algoritmo proposto para solucionar o problema. No entanto, a quantidade de iterações desenvolvidas durante o processo de treinamento também influenciará

a generalização de maneira direta. Daí decorrem os termos *overfitting* (superamostrado) e *underfitting* (subamostrado). Quando excessivamente amostrada (*overfitting*), a máquina tende a se especializar nos dados fornecidos durante o treinamento, perdendo capacidade de generalização. Logo, os atributos de saída estarão cada vez mais distantes do esperado quando forem utilizados atributos de entrada que não sejam oriundos do conjunto de dados do processo de treinamento. Se os dados são subamostrados (*underfitting*), o resultado também não convergirá. Nesse caso, a quantidade reduzida de iterações de aprendizagem é insuficiente para fazer as correções necessárias no conjunto de hipóteses e restringir a hipótese de solução para o menor e mais adequado subconjunto de dados possível.

3 Tarefas de aprendizado de máquina

As tarefas de aprendizado dizem respeito à forma como a máquina processa uma instância do conjunto de dados. A tarefa é executada tanto durante o treinamento quanto durante os testes e aplicações, mas não é responsável pelo acúmulo de conhecimento em si. As tarefas de aprendizado podem ser classificadas, segundo o paradigma de aprendizado, em preditivas ou descritivas (FACELI *et al.*, 2011). Tarefas preditivas, como sugere o nome, têm por finalidade prever os atributos de saída a partir da experiência passada. Já as tarefas descritivas analisam dados apenas passados e auxiliam a compreensão do conjunto desses dados. Nesse caso, a busca é por padrões e características em comum de dados já existentes que se caracterizam pela ausência de atributo alvo (FACELI *et al.*, 2011). Em ambos os casos, a experiência, no sentido de conhecimento acumulado durante processos de treinamento, tem impacto direto sobre o resultado, mesmo para as tarefas descritivas, já que a repetição de tentativas tende a melhorar o reconhecimento de características do conjunto de dados mesmo que este permaneça inalterado.

Diferentes tarefas são desenvolvidas constantemente e, a depender do critério, outras classificações podem ser adotadas, por exemplo, as formas como se realizam predições ou descrições de dados, que podem ser classificação, regressão e agrupamento. A classificação de dados utiliza um conjunto finito de hipóteses para rotular os atributos previsores. Trata-se de um método discreto em que o atributo alvo corresponde a um rótulo que descreve a combinação dos atributos previsores de uma instância. Um exemplo de classificação é utilizado nos servidores de *e-mail* para determinar quais *e-mails* deverão ser rotulados como *spam*.

O exemplo anterior parece simples, já que divide os dados em apenas duas categorias. No entanto, é um problema típico de inteligência artificial e, principalmente, de aprendizado de máquina, porque não há uma regra específica que defina o que é ou não uma mensagem de *spam*. O que pode ser indesejado para determinado usuário, pode não ser para outro. Assim, não apenas as características observadas para se determinar a classificação são variáveis e bastante complexas em alguns casos como também elas devem ser necessariamente aprendidas durante o uso do sistema pelo usuário, já que cada um se comporta e tem preferências diferentes de conteúdo.

A Figura 2 demonstra um conjunto de dados separado em duas classes. As classes representam o diagnóstico dos pacientes que podem ser saudáveis ou doentes. A decisão é tomada com base em dois exames que servem de atributos de entrada.

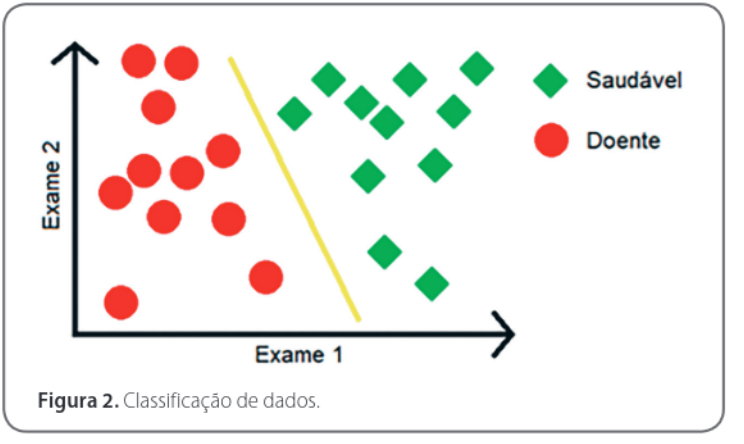


Figura 2. Classificação de dados.

A classificação pode ainda ser multirrótulos, determinando mais que uma categoria para cada instância. Nesse caso, a imagem da Figura 2 seria separada em mais que dois grupos. A regressão, por sua vez, é um método estatístico de previsão cujo atributo alvo corresponde a valores contínuos e, portanto, de infinitas possibilidades (FACELI *et al.*, 2011). Como exemplo, pode-se citar algoritmos de avaliação de preço de ativos, previsão meteorológica, antecipação de demandas e preços, entre outros. A Figura 3 traz um exemplo de previsão meteorológica que utiliza um algoritmo de regressão por aprendizado de máquina.

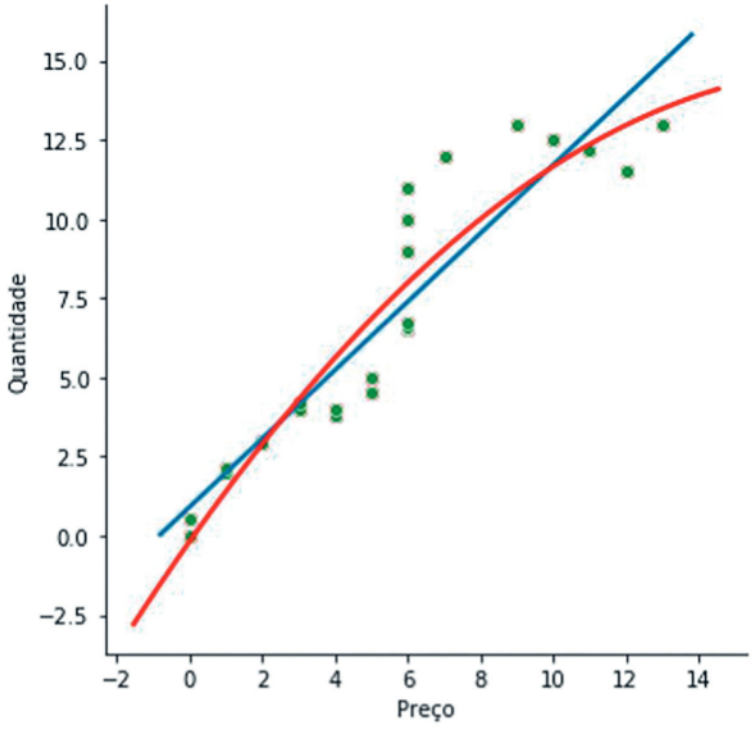


Figura 3. Algoritmo de regressão.

Dois métodos de regressão foram apresentados na Figura 3, regressão linear, em azul, e regressão polinomial em vermelho. A primeira possui apenas dois parâmetros (viés e peso) que definem uma reta, enquanto a segunda apresenta o mesmo problema resolvido a partir de um algoritmo de regressão polinomial. Nesse caso, a expressão possui coeficientes com dimensões maiores do que um, criando curvas que podem se aproximar ainda mais da distribuição dos dados. Desse modo, a maior precisão acarreta também maior complexidade de cálculo.

Em todos os casos, obteve-se um resultado aproximado da resposta correta, ainda que, para os modelos de resolução não linear, os resultados tenham sido mais precisos. No entanto, existem problemas que não são linearmente separáveis, e o modelo de aprendizado deverá se comportar de forma não linear para que se possa obter um resultado válido.

Pode-se imaginar diversas situações em que a solução é resultado de uma função não linear, mas um problema tão simples quanto o comportamento de uma função lógica ou exclusiva, com apenas duas variáveis de entrada e quatro combinações possíveis de saída, demonstra o problema de maneira satisfatória. Não existe reta capaz de separar as saídas verdadeiras das falsas, como no exemplo da Figura 4.

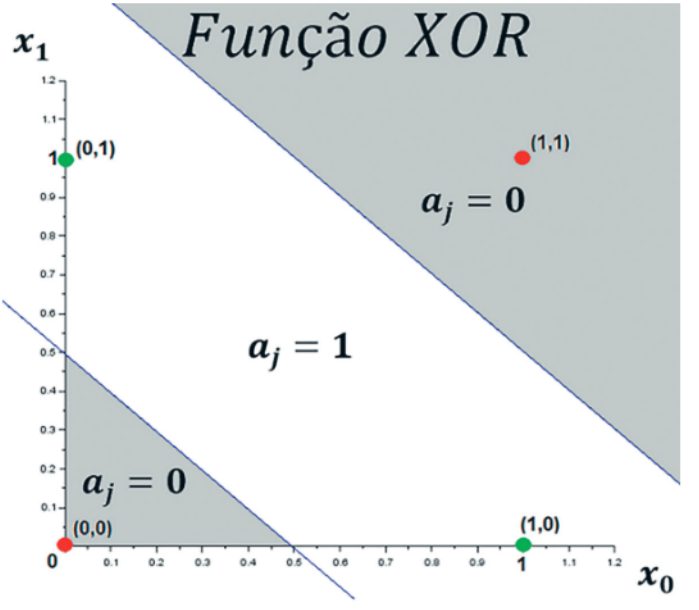


Figura 4. Função não linear.

Fique atento

É importante destacar que problemas de não linearidade são comuns em qualquer método de aprendizado de máquina e não apenas nos que utilizam o modelo de regressão.

Por fim, o agrupamento de dados (do inglês, *clustering*) busca características similares entre as instâncias de um conjunto de dados que não dispõe de um atributo alvo. Não visa à previsão de algum atributo alvo, mas à descrição do conjunto de dados, buscando nele padrões próprios que possam separar os dados em grupos menores de características similares.

O agrupamento é muito utilizado para tentar descrever grandes volumes de dados na tentativa de encontrar relações até então desconhecidas entre os atributos. Por exemplo, uma empresa pode querer saber qual é a melhor campanha de *marketing* a se adotar partindo das informações de vendas anteriores com dados relevantes a respeito dos consumidores. Nesse exemplo, não há um rótulo correto, tampouco o desenvolvedor ou o dono da empresa conhecem o provável resultado. Pelo contrário, é justamente por desconhecer as relações entre os dados que esse tipo de aprendizado é utilizado (JAMES *et al.*, 2013).

Os grupos encontrados em um conjunto de dados recebem o nome de *cluster* (grupo, em português), daí o motivo pelo qual esse método é geralmente referenciado como *clustering* (agrupamento, em português). Os grupos formados pela máquina são, em geral, conhecidos como *cluster*, mas carecem de definição mais precisa sobre do que se constituem, o que torna a escolha do algoritmo a ser utilizado muito abrangente (FACELI *et al.*, 2011).

A Figura 5 apresenta três métodos diferentes de agrupamento para um mesmo conjunto de dados (Figura 5a). O objetivo é encontrar características em comum. Assim, a Figura 5b agrupa as instâncias pelo formato, separando retangulares de redondos, a Figura 5c agrupa pela cor, criando também dois grupos, e a Figura 5d agrupa segundo as duas características, o que cria quatro grupos diferentes.

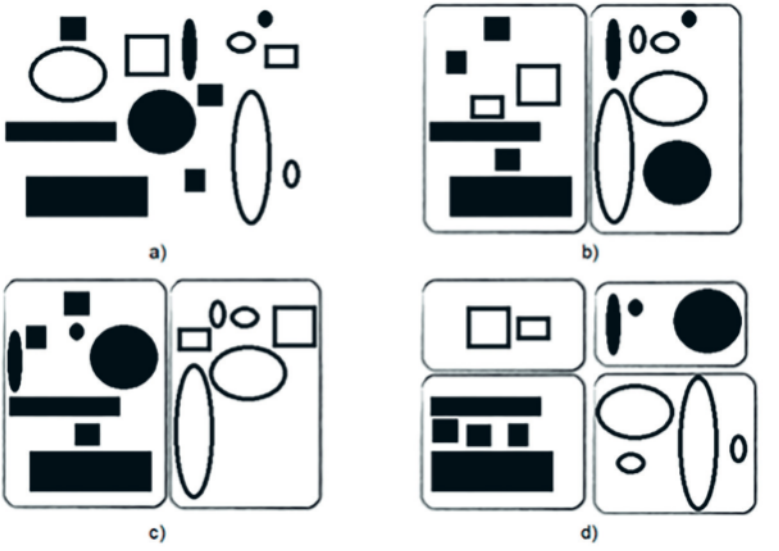


Figura 5. (a) Conjunto de dados de entrada. (b) Formato dos objetos utilizado como característica de agrupamento. (c) Agrupamento com base na cor das imagens. (d) Quatro grupos são formados quando ambas as características são adotadas.

Diferentes abordagens de aprendizado de máquina foram desenvolvidas ao longo do tempo. Sejam os algoritmos preditivos ou descritivos, orientados para a classificação, regressão ou agrupamento, todos têm por finalidade acumular conhecimento sobre determinado conjunto de dados, utilizando técnicas de treinamento para melhorar o modelo que relacionar os atributos de entrada a um alvo ou grupo de dados.

Os benefícios do aprendizado de máquina são muitos e incluem: processamento de conjuntos complexos e volumosos de dados, como em tarefas de agrupamento em que nem mesmo o desenvolvedor tem conhecimento suficiente a respeito; detecção de características que permitam à máquina compreender e realizar funções difíceis de serem expressas em instruções lógicas para executar, como em aplicações de identificação de imagens; possibilidade de adaptação contínua do algoritmo durante a aplicação, criando soluções customizadas ao contexto em que se encontram.

Referências

COPPIN, B. *Inteligência artificial*. Rio de Janeiro: LTC, 2010.

FACELI, K. *et al. Inteligência artificial*: uma abordagem de aprendizado de máquina. Rio de Janeiro: LTC, 2011.

JAMES, G. *et al. An introduction to statistical learning*: with applications in R. New York: Springer, 2013.

MITCHELL, T. *Machine learning*. Lexington: McGraw-Hill Science, 1997.

WITTEN, I. H.; FRANK, E. *Data mining*: practical machine learning tools and techniques. 2nd ed. Boston: Morgan Kaufmann, 2005.

Leituras recomendadas

NILSSON, N. J. *Artificial intelligence*: a new synthesis. San Francisco: Morgan Kaufmann, 1998.

RUSSELL, S. J.; NORVIG, P. *Inteligência artificial*. 2. ed. Rio de Janeiro: Campus, 2004.

Encerra aqui o trecho do livro disponibilizado para esta Unidade de Aprendizagem. Na Biblioteca Virtual da Instituição, você encontra a obra na íntegra.

Conteúdo:

SAGAH
SOLUÇÕES EDUCACIONAIS INTEGRADAS